

Profil Sociodémographique des étudiants Data chez OpenClassrooms (2022-2025)

Gwenaëlle Boussès

Contexte et objectifs



Pourquoi : mieux connaître
le profil de nos étudiants
afin d'adapter nos formations



Ce qu'on va voir :
qui ils sont, d'où ils viennent,
l'évolution en 4 ans

Méthodologie : traitement et enrichissement des données



Source: fichier csv contenant des informations sur les étudiants OpenClassrooms




Import du fichier sur Snowflake



Enrichissement des données à l'aide de fichiers provenant du site internet de l'Insee



Traitement des données sur dbt (outil d'automatisation et de nettoyage des données)



Traitement des données dans dbt

File explorer



data_OC_profil_sd

analyse_profiles

- > analyses
- > dbt_packages
- > logs
- > macros
- > models
 - > intermediate
 - > marts
 - > sources
 - > staging
- > seeds
- > target
- > tests

.gitignore

.gitkeep

dbt_project.yml

Traitement des données par étapes : des données brutes au fichier final

Exemple de traitement des données : le fichier « informations des étudiants »
Pas de données nominatives : respect du RGPD

data_OC_profil_sd > analyse_profiles > models > staging > stg_students_info.sql

Save

```
1  select
2      concat(user_id, '_', year_path_started) as student_year_id,
3      user_id,
4      path_category_name,
5      age_group as oc_age_group,
6      case
7          when age_group in ('20-24 ans') then '15-24 ans'
8          when age_group in ('25-29 ans', '30-34 ans', '35-39 ans', '40-44 ans', '45-49 ans') then '25-49 ans'
9          when age_group in ('50-54 ans', '55-59 ans', '60 ans ou plus') then '50 ans ou plus'
10         else 'unknown'
11     end as insee_age_group,
12     coalesce(gender, 'unknown') as gender,
13     upper('{{ clean_accents('REGION') }}') as region,
14     year_path_started
15 from {{ source('data_analysis', 'students_info') }}
```


Traitement des données dans dbt

Documentation et test des données afin de garantir leur fiabilité

```
3 models:
4   - name: stg_students_info
5     description: informations about openclassrooms students
6     columns:
7       - name: student_year_id
8         description: primary key, concatenation of user_id and year_path_started
9         data_tests:
10           - unique
11           - not_null
12       - name: user_id
13         data_tests:
14           - not_null
15       - name: oc_age_group
16         description: age groups in the raw openclassrooms data
17         data_tests:
18           - accepted_values:
19             arguments:
20               values: ['20-24 ans', '25-29 ans', '30-34 ans', '35-39 ans', '40-44 ans', '45-49 ans', '50-54 an
21       - name: insee_age_group
22         description: age groups according to insee data
23         data_tests:
24           - accepted_values:
25             arguments:
26               values: ['15-24 ans', '25-49 ans', '50 ans ou plus']
```


```
1 select * from {{ ref('stg_insee_chomage_age')}} where Annee > year(current_date())
```

Profil global des étudiants




Profil global des étudiants : Une majorité d'hommes trentenaires en reconversion


Proportion d'étudiants par genre




Nombre d'étudiants par tranche d'âge



Analyse géographique et économique : des étudiants principalement franciliens




Évolution dans le temps : en baisse depuis 2022, un rebond en 2025




Évolution dans le temps

Evolution de la proportion d'étudiants en fonction du genre



Environ 30% de femmes, un nombre qui reste stable

Evolution de la proportion d'étudiants en fonction de l'âge




Les 25-49 ans toujours en grande majorité

Analyse économique : lien avec le chômage

Le taux de chômage est quasiment identique selon le genre, cependant les inscrits aux formations OpenClassrooms sont à 70 % des hommes.


Comparaison effectifs/taux de chômage en fonction du genre



Analyse économique : lien avec le chômage

Le taux de chômage est environ 3 fois plus élevé chez les 15-24 ans que chez les 25-49 ans. Ces derniers représentent cependant 85% des étudiants chez OpenClassrooms, alors que les 15-24 ans ne représentent que 4% des effectifs.


Comparaison effectifs/taux de chômage en fonction de la tranche d'âge



Analyse économique : lien avec le chômage

Le taux de chômage est environ 2 fois plus élevé dans les DROM, alors que moins de 4% des étudiants OpenClassrooms y habitent.

La grande majorité des étudiants OpenClassrooms habitent en Ile-de-France, alors que le taux de chômage n'y est pas plus élevé que dans les autres régions métropolitaines.



Les étudiants OpenClassrooms dans les formations data sont



à 70 % des hommes



à 85 % des 25-49 ans



à 44 % des Franciliens

Améliorer la mixité
des étudiants

- Campagne ciblée sur les femmes
- Partenariat avec des associations comme *Women in Data* ou *Ada Tech School*

Attirer plus
d'étudiants en
formation initiale

- Campagne ciblée sur les possibilités d'alternance chez OpenClassrooms
- Mettre en avant l'employabilité immédiate

Cibler les territoires
à fort enjeu d'emploi
(ex: DROM)

- Campagne mettant en avant l'accessibilité de nos formations 100 % en ligne
- Partenariats avec les acteurs locaux de l'emploi

Égalité des
chances